

MONA

- Données hétérogènes
- Œuvres produites par plusieurs acteurs
- Non normalisées
- Riches sémantiquement (noms propres, lieux, périodes, catégories....)

Valeur VS Coût

Outil	Valeur Ajoutée	Coût en temps	Complexité
OpenRefine	Très élevée	Faible	Faible
AirFlow	Moyenne à élevée	Élevé	Élevée

POURQUOI?

OpenRefine

- Très utile en raison de la nature des données donc permet de détecter les incohérences de façon plus rapide
- Coût en temps : prise en main rapide en raison de la simplicité de l'interface graphique, concepts intuitifs, pas besoin de coder lourdement
- Complexité faible car l'installation est simple, l'architecture n'est pas distribuée et les dépendances ne sont pas lourdes

AirFlow

- Valeur ajoutée dans MONA :
 - a. si on a des pipelines récurrents - EXCELLENT
- Coût en temps :
 - Installation
 - configuration de la base de métadonnées
 - comprendre la logique DAGs
 - écrire la structure du pipeline
 - temps d'apprentissage : il est important de maîtriser les DAGs/ Operators / gestion des dépendances ..etc
- Complexité : l'outil introduit
 - plusieurs composants (scheduler, webserver, metadata DB)
 - une architecture distribuée potentielle
 - Le pipeline doit être pensé en tâches atomiques avec dépendances explicites et une gestion des erreurs

Avis trouvés sur Reddit à propos des deux outils

OpenRefine : généralement conseillé, réputé pour optimiser le temps

AirFlow : Avis mitigés

- interface user pas super, nombreux paramètres à configurer, parfois des bugs de scheduler à contourner
- certaines personnes estiment que pour des volumes importants ou un usages orienté ingestion ce n'est pas le meilleur des outils